

Sistema RAG para Suporte à Decisão Farmacêutica

Sistema baseado em Retrieval-Augmented Generation para apoio à decisão em contexto farmacêutico.

Liane Duarte al79012

Orientadores:

Ricardo Costa | Paulo Moura Oliveira | Eduardo Solteiro Pires

Resumo - rascunho

A crescente complexidade da informação farmacêutica representa um desafio significativo para os profissionais de saúde, que necessitam de acesso rápido e fiável a conhecimento especializado proveniente de bulas, fichas técnicas de medicamentos e orientações clínicas e regulamentares. Os modelos de linguagem de grande escala (Large Language Models, LLMs) surgem como uma solução promissora, mas apresentam limitações importantes, nomeadamente o conhecimento estático após o treino e a tendência para gerar respostas incorretas, um fenómeno designado por alucinação.

Este projeto propõe o desenvolvimento de um sistema baseado em Retrieval-Augmented Generation (RAG) para suporte à decisão em contexto farmacêutico português. O sistema combina recuperação híbrida de informação com geração de linguagem natural, fundamentando as respostas em documentação farmacêutica oficial nacional, bulas, monografias, guias terapêuticos e normas do INFARMED, e permitindo rastrear a origem de cada resposta até à fonte documental utilizada. A arquitetura adotada combina os paradigmas Advanced RAG, Modular RAG e CRAG, implementada com o modelo generativo Claude 3.5 Sonnet da Anthropic, o modelo de *embedding* Gemini *Embedding* 2 da Google e a base de dados vetorial Qdrant, orquestrada com LangChain e exposta através de uma API REST desenvolvida com FastAPI.

O sistema distingue-se dos trabalhos existentes na literatura em três dimensões. Em primeiro lugar, opera integralmente em língua portuguesa sobre documentação farmacêutica regulada pelo INFARMED, colmatando a lacuna identificada na revisão sistemática quanto à escassez de sistemas RAG biomédicos adaptados a contextos multilingues e a documentação proprietária nacional. Em segundo lugar, integra mecanismos de segurança e conformidade com o RGPD e o EU AI Act para sistemas de alto risco, garantindo rastreabilidade, supervisão humana e aviso de responsabilidade obrigatório em cada resposta gerada. Em terceiro lugar, incorpora mecanismos de avaliação e correção da recuperação inspirados no CRAG, aumentando a robustez do sistema perante documentação insuficiente ou ambígua.

O desempenho do sistema é avaliado com recurso ao *framework* Retrieval-Augmented Generation Assessment (RAGAS), que permite medir automaticamente a qualidade da recuperação e da geração de respostas em dimensões como fidelidade ao contexto, relevância e cobertura, em cenários representativos de utilização farmacêutica real.

Palavras-chave: Retrieval-Augmented Generation, Large Language Models, Suporte à Decisão Farmacêutica, INFARMED, Inteligência Artificial, Português

Nota: O presente resumo será completado com os principais resultados da avaliação do sistema após a conclusão do Capítulo 5.

Abstract – rascunho

The increasing complexity of pharmaceutical information poses a significant challenge for healthcare professionals, who require fast and reliable access to specialised knowledge from medication package inserts, technical data sheets, and clinical and regulatory guidelines. Large Language Models (LLMs) have emerged as a promising solution, but present important limitations, namely static knowledge after training and a tendency to generate incorrect responses, a phenomenon known as hallucination.

This project proposes the development of a Retrieval-Augmented Generation (RAG) based system for decision support in the Portuguese pharmaceutical context. The system combines hybrid information retrieval with natural language generation, grounding responses in official national pharmaceutical documentation, package inserts, monographs, therapeutic guides, and INFARMED regulations, and enabling full traceability of each response to its source documents. The adopted architecture combines the Advanced RAG, Modular RAG, and CRAG paradigms, implemented with Anthropic's Claude 3.5 Sonnet generative model, Google's Gemini Embedding 2 embedding model, and the Qdrant vector database, orchestrated with LangChain and exposed through a FastAPI REST interface.

The system distinguishes itself from existing work in the literature across three dimensions. First, it operates entirely in Portuguese over pharmaceutical documentation regulated by INFARMED, addressing the gap identified in the systematic review regarding the scarcity of biomedical RAG systems adapted to multilingual contexts and national proprietary documentation. Second, it integrates guardrail mechanisms and compliance with the GDPR and the EU AI Act for high-risk AI systems, ensuring traceability, human oversight, and mandatory disclaimers on every generated response. Third, it incorporates retrieval evaluation and correction mechanisms inspired by CRAG, improving system robustness in scenarios where available documentation is insufficient or ambiguous.

System performance is evaluated using the Retrieval-Augmented Generation Assessment (RAGAS) framework, which enables automatic measurement of retrieval and response generation quality across dimensions such as context fidelity, relevance, and coverage, in scenarios representative of real pharmaceutical usage.

Keywords: Retrieval-Augmented Generation, Large Language Models, Pharmaceutical Decision Support, INFARMED, Artificial Intelligence, Portuguese

Índice

1 - Introdução.....	9
1.1 - Contexto e motivação.....	9
1.2 - Objetivos.....	10
1.3 - Metodologia de desenvolvimento.....	11
2 - Enquadramento teórico.....	12
2.1 - Large Language Models	12
2.1.1 - Fundamentos e arquitetura <i>Transformer</i>	12
2.1.2 - Limitações dos LLMs.....	13
2.2 - Retrieval-Augmented Generation	13
2.2.1 - Fundamentos do RAG.....	13
2.2.2 – Evolução das arquiteturas	15
2.2.3 - Avaliação de sistemas RAG.....	17
2.3 - Componentes técnicos de um sistema RAG.....	18
2.3.1 - Estratégias de <i>chunking</i>	18
2.3.2 - Modelos de <i>embedding</i>	20
2.3.3 - Bases de dados vetoriais	21
2.4 - IA no Domínio Farmacêutico	22
2.4.1 - Aplicações de IA em Saúde.....	22
2.4.2 - RAG Aplicado à Farmácia	23
2.4.3 - Enquadramento Regulatório	24
3 - Estado da Arte.....	27
3.1 - Metodologia de Revisão Sistemática.....	27
3.1.1 - Perguntas de Investigação	27
3.1.2 - Estratégia de Pesquisa.....	27
3.1.3 - Critérios de Seleção.....	28
3.1.4 - Processo de Seleção e Resultados.....	28
3.2 – Síntese dos Estudos Incluídos	30
3.3 Análise Crítica	32
4 - Desenvolvimento do Sistema.....	35

4.1 - Requisitos	35
4.1.1 - Requisitos Funcionais	35
4.1.2 - Requisitos Não Funcionais	36
4.2 - Arquitetura do Sistema.....	38
4.2.1 - Decisão Arquitetural.....	38
4.2.2 – Visão Geral do Sistema	40
4.2.3 - <i>Pipeline</i> de Ingestão	41
4.2.4 - <i>Pipeline</i> de Consulta	43
4.2.5 - Mecanismos de Segurança.....	45
4.3 - Implementação.....	46
4.3.1 – Conjunto de Tecnologias	46
4.3.2 - Processamento e Indexação de Documentos	48
4.3.3 - Recuperação e Geração de Respostas	48
4.3.4 - Interface e Disponibilização	48
5 - Avaliação e Resultados – por fazer	48
5.1 - Métricas de Avaliação.....	48
5.2 - Resultados	48
5.3 - Discussão	48
6 – Conclusão - por fazer.....	48

Lista de Figuras

Figura 1 - <i>Pipeline</i> de um sistema RAG	14
Figura 2 - Evolução das arquiteturas RAG.....	15
Figura 3 - Estratégias de <i>chunking</i>	19
Figura 4 - Conversão de texto em <i>embeddings</i>	20
Figura 5 - <i>Pipeline</i> de um sistema RAG aplicado ao domínio farmacêutico	23
Figura 6 - Fluxograma PRISMA do processo de seleção de artigos	30
Figura 7 - Arquitetura geral do sistema	40
Figura 8 - <i>Pipeline</i> de ingestão	42
Figura 9 - <i>Pipeline</i> de consulta	44

Lista de Tabelas

Tabela 1 - Resultados do processo de seleção PRISMA por subsecção.....	29
Tabela 2 - Síntese dos estudos incluídos e contribuição para o projeto	32
Tabela 3 - Requisitos funcionais do sistema	36
Tabela 4 - Requisitos não funcionais do sistema	37
Tabela 5 - Comparação das arquiteturas RAG consideradas.....	39

Lista de Acrónimos

AI	Artificial Intelligence
ANN	Approximate Nearest Neighbor
API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
CDSS	Clinical Decision Support Systems
CRAG	Corrective Retrieval-Augmented Generation
FAISS	Facebook AI Similarity Search
GPT	Generative Pre-trained Transformer
GraphRAG	Graph Retrieval-Augmented Generation
INFARMED	Instituto Nacional da Farmácia e do Medicamento
LLM	Large Language Model
NLP	Natural Language Processing
OCR	Optical Character Recognition
PDF	Portable Document Format
PRISMA	Preferred Reporting Items for Systematic Reviews and Meta-Analyses
QA	Question Answering
RAG	Retrieval-Augmented Generation
RAGAS	Retrieval-Augmented Generation Assessment
RALM	Retrieval-Augmented Language Model
RAPTOR	Recursive Abstractive Processing for Tree-Organized Retrieval
REST	Representational State Transfer
RGPD	Regulamento Geral sobre a Proteção de Dados
Self-RAG	Self-Reflective Retrieval-Augmented Generation
LightRAG	Simple and Fast Retrieval-Augmented Generation
MEDRAG	Medical Retrieval-Augmented Generation
MIRAGE	Medical Information Retrieval-Augmented Generation Evaluation

1 - Introdução

1.1 - Contexto e motivação

O setor farmacêutico caracteriza-se por uma densidade de informação técnica e regulatória sem paralelo em muitas outras áreas de atividade. Farmacêuticos e técnicos de farmácia necessitam de aceder, de forma rápida e fiável, a informação sobre medicamentos, interações, posologias, contraindicações e protocolos terapêuticos, dispersa por um vasto corpus documental que inclui bulas, monografias, guias terapêuticos, formulários hospitalares e normas do INFARMED. A gestão eficiente deste volume de informação representa um desafio crescente, agravado pela constante atualização do conhecimento farmacêutico: novas aprovações de medicamentos, revisões de orientações e alertas de segurança são publicados regularmente, tornando os sistemas de informação estáticos rapidamente desatualizados.

Os modelos de linguagem de grande escala (Large Language Models, LLMs) surgem como uma resposta promissora a este desafio, demonstrando capacidade para compreender questões clínicas em linguagem natural e gerar respostas contextualmente adequadas. No entanto, a sua adoção em contextos farmacêuticos enfrenta limitações importantes que os tornam inadequados para utilização direta neste domínio, conforme detalhado no Capítulo 2.

O paradigma Retrieval-Augmented Generation (RAG) surge como resposta direta a essas limitações, constituindo a abordagem central do presente projeto. A evidência empírica disponível na literatura demonstra que sistemas RAG especializados, construídos sobre documentação farmacêutica estruturada, conseguem superar tanto os LLMs genéricos como as implementações RAG não especializadas em tarefas de suporte à decisão clínica.

A implementação de sistemas de IA em contexto farmacêutico está ainda sujeita a um conjunto de obrigações regulatórias que condicionam o seu *design* e disponibilização. O RGPD classifica os dados de saúde como categoria especial de dados pessoais, exigindo medidas reforçadas de proteção e privacidade. O EU AI Act classifica os sistemas de IA de suporte à decisão clínica como sistemas de alto risco, impondo requisitos de transparência, rastreabilidade e supervisão humana. Estas obrigações regulatórias, longe de constituírem apenas restrições, definem um conjunto de princípios de *design* que contribuem para a fiabilidade e segurança do sistema.

A maioria dos sistemas RAG desenvolvidos até ao momento recorre a bases de conhecimento públicas em inglês, com escassa adaptação a contextos multilingues ou a documentação

regulatória nacional. Esta lacuna é particularmente relevante para o contexto farmacêutico português, onde a documentação clínica, os regulamentos do INFARMED e as orientações nacionais seguem convenções linguísticas e regulatórias próprias. O presente projeto posiciona-se precisamente nesta lacuna, propondo o desenvolvimento de um sistema RAG orientado ao suporte à decisão farmacêutica em português, construído sobre documentação farmacêutica oficial portuguesa e alinhado com o quadro regulatório europeu aplicável.

1.2 - Objetivos

O objetivo geral deste projeto é desenvolver e avaliar um sistema baseado em Retrieval-Augmented Generation para suporte à decisão farmacêutica em português, com foco na qualidade e rastreabilidade das respostas geradas, na implementação de mecanismos de segurança adequados ao domínio clínico e na conformidade com os requisitos regulatórios aplicáveis.

Para concretizar este objetivo, foram definidos os seguintes objetivos específicos:

- Realizar uma revisão sistemática da literatura sobre arquiteturas RAG, técnicas de recuperação e geração, e aplicações de inteligência artificial em saúde e farmácia, de forma a fundamentar as decisões de *design* do sistema numa base empírica sólida.
- Analisar e selecionar a arquitetura RAG mais adequada ao domínio farmacêutico, com base em critérios de precisão, rastreabilidade, robustez e conformidade regulatória, justificando as escolhas face às alternativas consideradas.
- Desenvolver um *pipeline* de ingestão capaz de processar documentação farmacêutica oficial portuguesa em formato PDF, incluindo extração de texto e tabelas, segmentação em *chunks*, geração de *embeddings* e indexação numa base de dados vetorial com metadados estruturados.
- Desenvolver um *pipeline* de consulta com recuperação híbrida, *reranking* e mecanismos de avaliação e correção inspirados no CRAG, que permita responder a questões clínicas em linguagem natural com citação explícita das fontes utilizadas.
- Implementar mecanismos de segurança que garantam a validação da entrada, a fidelidade das respostas ao contexto recuperado e a conformidade com os requisitos de transparência e supervisão humana do EU AI Act.

- Avaliar o desempenho do sistema com recurso ao *framework* RAGAS, medindo dimensões como fidelidade, relevância da resposta e precisão do contexto, em cenários representativos de utilização farmacêutica real.

1.3 - Metodologia de desenvolvimento

O desenvolvimento do presente projeto seguiu uma abordagem iterativa e incremental, organizada em três fases sequenciais que refletem a progressão natural de um projeto de investigação aplicada em engenharia informática.

A primeira fase, de planeamento e investigação, compreendeu a revisão sistemática da literatura sobre arquiteturas RAG, técnicas de *embedding* e recuperação, e aplicações de inteligência artificial em saúde e farmácia, seguindo a metodologia PRISMA. Esta fase incluiu ainda a análise do enquadramento regulatório aplicável, a definição dos requisitos do sistema e a seleção e justificação da arquitetura e conjunto tecnológico.

A segunda fase, de implementação, compreendeu o desenvolvimento dos dois *pipelines* principais do sistema (ingestão e consulta) e da camada de mecanismos de segurança, seguindo a arquitetura definida na fase anterior. O desenvolvimento foi realizado de forma incremental, começando pelo *pipeline* de ingestão e validando cada componente antes de avançar para o seguinte, de forma a detetar e corrigir problemas de forma antecipada.

A terceira fase, de avaliação e consolidação, compreendeu a definição de um conjunto de perguntas de teste representativas de cenários reais de utilização farmacêutica, a execução de experiências com o sistema desenvolvido e a recolha e análise de métricas de desempenho com recurso ao *framework* RAGAS. Esta fase incluiu ainda a redação final do relatório, a elaboração do poster e a preparação da apresentação pública.

Do ponto de vista das ferramentas e métodos utilizados, a gestão bibliográfica foi realizada com recurso ao Consensus e ao Mendeley, os diagramas foram elaborados com o draw.io e o desenvolvimento do sistema recorreu às tecnologias descritas na secção 4.3.1. O controlo de versões do código foi assegurado através do Git e GitHub.

2 - Enquadramento teórico

Este capítulo apresenta os conceitos fundamentais necessários à compreensão do sistema desenvolvido. Começa por introduzir os Large Language Models, descrevendo o seu funcionamento e principais limitações. De seguida, apresenta o paradigma Retrieval-Augmented Generation como resposta a essas limitações, cobrindo a evolução das arquiteturas, os componentes técnicos do *pipeline* e os métodos de avaliação. O capítulo termina com uma contextualização do domínio farmacêutico, enquadrando a aplicação de IA e RAG neste contexto específico.

2.1 - Large Language Models

2.1.1 - Fundamentos e arquitetura *Transformer*

Os Large Language Models (LLMs) são modelos de inteligência artificial treinados sobre grandes volumes de texto, capazes de compreender e gerar linguagem natural com elevado grau de fluência. Exemplos proeminentes incluem o GPT-4 da OpenAI, o LLaMA da Meta e o Gemini da Google, modelos que demonstraram capacidades notáveis em tarefas como resposta a perguntas, resumo de texto, tradução e geração de código.

O funcionamento destes modelos assenta na arquitetura *Transformer*, introduzida por Vaswani et al. (2017), que substituiu as redes recorrentes tradicionais por mecanismos de atenção capazes de capturar dependências entre palavras independentemente da sua distância no texto. O mecanismo central desta arquitetura é o *self-attention*, que permite ao modelo determinar, para cada palavra de uma frase, quais as outras palavras mais relevantes para compreender o seu significado. Por exemplo, numa frase como "o medicamento foi administrado ao paciente, que o tolerou bem", o modelo consegue associar o pronome "o" ao "medicamento" e o "que" ao "paciente", mesmo que estejam distantes no texto. Esta capacidade de modelar relações de longo alcance tornou os *Transformers* particularmente adequados para tarefas de compreensão e geração de linguagem.

Estes modelos processam o texto sob a forma de *tokens*, unidades básicas que podem corresponder a palavras, sílabas ou caracteres, dependendo do vocabulário do modelo. O processo de geração consiste em prever, de forma iterativa, o *token* mais provável dado o contexto anterior, produzindo texto coerente e contextualmente adequado. Quando um utilizador interage com um LLM, fornece-lhe um *prompt*, um texto de entrada que orienta a

resposta do modelo. A qualidade e especificidade desse *prompt* influenciam diretamente a relevância da resposta produzida.

Os LLMs são pré-treinados com grandes coleções de texto provenientes da web, livros e outras fontes de forma não supervisionada, aprendendo representações ricas da linguagem sem necessidade de anotação manual. Este pré-treino pode depois ser complementado com *fine-tuning* supervisionado em tarefas específicas, permitindo adaptar o modelo a domínios ou objetivos concretos, como a medicina ou o direito.

2.1.2 - Limitações dos LLMs

Apesar das suas capacidades, os LLMs apresentam limitações importantes que condicionam a sua utilização em contextos que exigem precisão factual e atualidade da informação.

Em primeiro lugar, o conhecimento do modelo fica estático após o treino. Qualquer informação publicada depois do corte temporal do treino é desconhecida para o modelo, o que pode tornar as respostas desatualizadas em domínios em constante evolução, como a farmacologia, onde novas orientações, aprovações de medicamentos e alertas de segurança são publicados regularmente. Em segundo lugar, os LLMs não fornecem, por defeito, qualquer indicação sobre a origem da informação que geram, dificultando a verificação e rastreabilidade das respostas, uma limitação crítica em contextos clínicos onde a fonte da informação é tão importante quanto o seu conteúdo. Por último, estes modelos podem produzir respostas que parecem corretas, mas não o são, um fenómeno designado por **alucinação**. Este comportamento resulta de padrões estatísticos aprendidos durante o treino que nem sempre correspondem a factos verificáveis, um modelo pode, por exemplo, citar um medicamento inexistente ou atribuir uma indicação terapêutica incorreta a um fármaco real, com consequências potencialmente graves.

Estas limitações são particularmente problemáticas em domínios sensíveis como a saúde e a farmácia, onde a precisão da informação tem implicações diretas na segurança do utilizador. É precisamente para responder a estas fragilidades que surge o paradigma Retrieval-Augmented Generation, apresentado na secção seguinte.

2.2 - Retrieval-Augmented Generation

2.2.1 - Fundamentos do RAG

O paradigma Retrieval-Augmented Generation (RAG) surgiu como resposta direta às limitações dos LLMs descritas anteriormente. A ideia central é simples: em vez de o modelo depender

exclusivamente do conhecimento armazenado nos seus parâmetros durante o treino, o sistema consulta primeiro uma base de conhecimento externa e utiliza a informação recuperada para fundamentar a resposta gerada. Esta abordagem permite que o modelo aceda a informação atualizada sem necessidade de ser re-treinado, e torna possível rastrear a origem de cada resposta até aos documentos consultados (Lewis et al., 2020).

Na prática, um sistema RAG funciona em três fases sequenciais, ilustradas na Figura 1. Quando um utilizador coloca uma pergunta, esta é convertida numa representação numérica, designada *embedding*, que captura o seu significado semântico. Esta representação é então comparada com as representações dos documentos previamente armazenados numa base de dados vetorial, uma estrutura de armazenamento otimizada para encontrar rapidamente os documentos cujo conteúdo é semanticamente mais próximo da pergunta. Os documentos mais relevantes são recuperados e fornecidos como contexto adicional ao modelo generativo, que produz a resposta final com base nessa informação. Este processo é habitualmente descrito como um *pipeline* de três etapas: recuperação (*retrieve*), enriquecimento do contexto (*augment*) e geração (*generate*), que dão origem ao acrónimo RAG.




Figura 1 - Pipeline de um sistema RAG

Uma alternativa ao RAG para adaptar um LLM a um domínio específico seria o *fine-tuning*, que consiste em re-treinar o modelo com dados anotados desse domínio. No entanto, esta abordagem apresenta limitações significativas: é computacionalmente exigente, requer grandes volumes de dados anotados manualmente, e necessita de ser repetida sempre que a informação se altera. Além disso, mesmo após o *fine-tuning*, o modelo não consegue citar a fonte das suas respostas nem garantir que a informação está atualizada.

O RAG supera estas limitações de forma elegante. A base de conhecimento pode ser atualizada de forma independente, sem modificar o modelo, basta adicionar ou remover documentos. O custo de implementação é substancialmente inferior, não exige anotação manual de dados, e cada resposta pode ser rastreada até aos documentos que a fundamentaram. Esta combinação de flexibilidade, rastreabilidade e custo reduzido torna o RAG particularmente adequado para domínios onde a informação evolui rapidamente e onde a fiabilidade das respostas é crítica, como é o caso da farmácia.

2.2.2 - Evolução das arquiteturas

Após a formulação inicial do paradigma RAG, a investigação passou a concentrar-se nas limitações dos sistemas mais simples, sobretudo na dependência de uma única etapa de recuperação, na sensibilidade ao ruído documental e na dificuldade em lidar com perguntas complexas. A evolução das arquiteturas RAG pode ser entendida como uma tentativa progressiva de tornar o *pipeline* mais robusto, flexível e adaptado a cenários reais de utilização, conforme ilustrado na Figura 2.




Figura 2 - Evolução das arquiteturas RAG

O chamado Naive RAG corresponde à forma mais direta do paradigma: a pergunta do utilizador é convertida numa representação vetorial, o sistema recupera os documentos semanticamente mais próximos e estes são enviados ao modelo para geração da resposta. Apesar da sua simplicidade, esta arquitetura revela limitações importantes, nomeadamente baixa robustez a ruído, forte dependência da qualidade de recuperação e tendência para incluir contexto irrelevante no *prompt*.

Estas fragilidades motivaram o desenvolvimento do Advanced RAG, que introduz otimizações em diferentes momentos do *pipeline*. Entre essas melhorias incluem-se estratégias como reformulação de *queries*, recuperação híbrida, *reranking* e compressão contextual. Em vez de aceitar automaticamente os primeiros documentos recuperados, estas arquiteturas procuram refinar a seleção do contexto antes da geração, reduzindo ruído e aumentando a relevância da informação utilizada.

Outra evolução importante foi a transição para arquiteturas Modular RAG, em que o sistema deixa de ser visto como um *pipeline* rígido e passa a ser organizado em módulos independentes, ingestão, indexação, recuperação, *reranking*, roteamento e geração. Esta modularidade facilita a substituição de componentes, a integração de múltiplas fontes e a adaptação da arquitetura às exigências de diferentes aplicações, sendo particularmente relevante em ambientes de produção.

Paralelamente, surgiram arquiteturas orientadas para problemas mais complexos de estrutura e raciocínio. O GraphRAG incorpora grafos de conhecimento na indexação e recuperação, modelando relações entre entidades e conceitos. Em vez de tratar o corpus como um conjunto isolado de fragmentos, o sistema explora relações explícitas entre elementos do conhecimento, o que pode melhorar a coerência e contextualização da resposta em domínios ricos em dependências semânticas. O LightRAG estende esta abordagem com um sistema de recuperação a dois níveis, local e global, e suporte a atualização incremental de dados, tornando-a mais eficiente em cenários reais (Guo et al., 2024).

Mais recentemente, surgiram abordagens com mecanismos de autorregulação. O Self-RAG introduz a capacidade de o próprio modelo decidir quando recuperar informação adicional e avaliar a utilidade do contexto obtido. O CRAG foca-se na robustez da recuperação, incorporando mecanismos de avaliação da qualidade dos documentos recuperados e desencadeando ações corretivas quando essa recuperação é considerada insuficiente. Estas

abordagens refletem uma mudança importante: o processo de recuperação deixa de ser uma etapa fixa e passa a ser monitorizado e ajustado dinamicamente.

A evolução mais recente corresponde ao Agentic RAG, em que agentes inteligentes assumem um papel ativo na gestão do *pipeline*. Nestes sistemas, a resposta deixa de resultar de uma única recuperação seguida de geração, passando a envolver decomposição da tarefa, múltiplas pesquisas, seleção de ferramentas e reflexão intermédia. Esta arquitetura é particularmente promissora para problemas complexos e multi-passo, embora implique maior custo computacional e maior dificuldade de avaliação.

2.2.3 - Avaliação de sistemas RAG

A avaliação de sistemas RAG constitui uma etapa fundamental no seu desenvolvimento, uma vez que o desempenho destes sistemas não depende apenas da qualidade do modelo generativo, mas também da capacidade de recuperar contexto relevante e utilizá-lo corretamente na construção da resposta. Ao contrário de tarefas tradicionais de geração de texto, nos sistemas RAG é necessário avaliar pelo menos duas dimensões distintas: a qualidade da recuperação e a qualidade da geração fundamentada.

Na dimensão da recuperação, importa verificar se os documentos recuperados são efetivamente relevantes para a pergunta colocada, se cobrem a informação necessária para responder e se introduzem ou não ruído desnecessário no contexto. Um sistema pode falhar mesmo antes da geração, caso a recuperação devolva fragmentos incompletos, ambíguos ou pouco relacionados com a intenção do utilizador.

Na dimensão da geração, não basta verificar se a resposta soa correta, é necessário analisar se está alinhada com a evidência recuperada, se responde à pergunta de forma completa e se evita afirmações não suportadas pelo contexto. Os critérios mais relevantes incluem a fidelidade ao contexto, a relevância da resposta e a correção factual.

Uma contribuição importante neste domínio foi o *framework* RAGAS (Es et al., 2023), que propõe um conjunto de métricas automáticas para avaliar *pipelines* RAG sem necessidade de anotações humanas. O RAGAS opera sobre quatro métricas fundamentais, cada uma avaliando uma dimensão distinta do *pipeline*. A métrica de *faithfulness* mede em que medida as afirmações presentes na resposta gerada estão suportadas pelo contexto recuperado, sendo particularmente crítica em domínios clínicos onde respostas não fundamentadas podem induzir erros terapêuticos. A métrica de *answer relevancy* avalia se a resposta gerada é pertinente

relativamente à pergunta colocada, penalizando respostas incompletas ou que desviem do foco da questão. A métrica de *context precision* avalia se os *chunks* recuperados são efetivamente relevantes para a pergunta, penalizando a inclusão de fragmentos de baixa utilidade no *prompt* que possam degradar a qualidade da resposta ao introduzir ruído no raciocínio do modelo generativo. Por fim, a métrica de *context recall* mede se o conjunto de documentos recuperados contém toda a informação necessária para responder corretamente à pergunta, verificando se as afirmações relevantes estão cobertas pelo contexto recuperado. A combinação destas quatro métricas permite obter uma visão abrangente do desempenho do sistema, identificando separadamente falhas na recuperação e falhas na geração.

Não existe ainda uma metodologia única e universalmente aceite para avaliar sistemas RAG, e a escolha da abordagem deve estar alinhada com o contexto de aplicação e o nível de exigência factual do sistema. Em domínios críticos como o farmacêutico, torna-se especialmente importante avaliar não só a qualidade da resposta, mas também a rastreabilidade da informação e a robustez do sistema face a documentos ruidosos ou incompletos.

2.3 - Componentes técnicos de um sistema RAG

Para que um sistema RAG funcione corretamente, não basta dispor de um modelo generativo e de uma base de conhecimento, é necessário que os documentos sejam preparados, representados e indexados de forma adequada. Esta preparação é assegurada por um conjunto de componentes técnicos que determinam, em grande medida, a qualidade da informação recuperada e, consequentemente, a qualidade da resposta gerada. Os três componentes fundamentais são a segmentação dos documentos em unidades menores (*chunking*), a conversão dessas unidades em representações numéricas (*embeddings*) e o armazenamento dessas representações numa base de dados que permita recuperação eficiente por similaridade semântica.

2.3.1 - Estratégias de *chunking*

A segmentação de documentos, designada por *chunking*, constitui uma etapa fundamental nos sistemas RAG. Os modelos de linguagem não processam diretamente documentos extensos, têm um limite de contexto que determina a quantidade máxima de texto que podem receber de uma vez. Por este motivo, antes de serem indexados, os documentos são divididos em segmentos menores, denominados *chunks*, que passam a ser as unidades básicas de recuperação.

A forma como esta segmentação é realizada tem impacto direto na qualidade do sistema. *Chunks* demasiado pequenos podem não conter informação suficiente para responder a uma pergunta de forma completa, enquanto *chunks* demasiado grandes podem incluir informação irrelevante ou exceder os limites de contexto do modelo. A escolha do tamanho e da estratégia de segmentação representa, portanto, um compromisso entre granularidade e contexto, conforme ilustrado na Figura 3.




Figura 3 - Estratégias de *chunking*

A abordagem mais simples consiste na divisão do texto em segmentos de tamanho fixo, frequentemente com sobreposição entre *chunks* consecutivos. Esta sobreposição permite preservar continuidade semântica entre segmentos e reduzir a probabilidade de perda de informação relevante que se encontre na fronteira entre dois *chunks*. No entanto, pode introduzir redundância e aumentar o número de segmentos armazenados.


Existem também abordagens baseadas em segmentação semântica, em que os documentos são divididos com base na estrutura do texto, frases, parágrafos ou secções temáticas, garantindo que cada *chunk* representa uma unidade de significado coerente. Estudos em contexto hospitalar mostram que a escolha da estratégia de *chunking* e do tamanho dos segmentos tem impacto significativo no desempenho do sistema, influenciando tanto a relevância dos documentos recuperados como a qualidade da resposta final (Bossenz et al., 2025).

2.3.2 - Modelos de *embedding*

Após a segmentação dos documentos em *chunks*, cada segmento precisa de ser convertido numa representação numérica que capture o seu significado semântico. Esta representação é designada por *embedding*, um vetor de números reais que posiciona o *chunk* num espaço multidimensional de forma que textos com significados semelhantes fiquem próximos entre si, independentemente das palavras exatas utilizadas. Por exemplo, as frases "o medicamento reduz a febre" e "o fármaco tem efeito antipirético" terão *embeddings* próximos no espaço vetorial, mesmo sendo formuladas de forma diferente.

Esta propriedade é fundamental para o funcionamento do RAG. Quando um utilizador coloca uma pergunta, esta é convertida no mesmo espaço vetorial pelo mesmo modelo de *embedding*, e o sistema identifica os *chunks* mais relevantes calculando a similaridade entre o vetor da pergunta e os vetores dos documentos armazenados, representado na Figura 4. A métrica mais comum para medir esta similaridade é a similaridade de cosseno, que mede o ângulo entre dois vetores independentemente da sua magnitude, quanto menor o ângulo, maior a similaridade semântica.

1. Indexação (fase de ingestão)



2. Recuperação (fase de query)




Figura 4 - Conversão de texto em *embeddings*

Os modelos de *embedding* são redes neurais treinadas para aprender estas representações a partir de grandes volumes de texto. Modelos como o BERT e as suas variantes aprendem representações contextuais, ou seja, o *embedding* de uma palavra ou frase tem em conta o contexto em que aparece. Mais recentemente, modelos como os da família *sentence-transformers* foram desenvolvidos especificamente para produzir *embeddings* de frases e parágrafos completos, sendo amplamente utilizados em sistemas RAG.

A qualidade do modelo de *embedding* tem impacto direto na qualidade da recuperação, um modelo que não represente adequadamente o vocabulário do domínio pode recuperar documentos semanticamente distantes da pergunta, comprometendo a resposta final. Por este motivo, a escolha do modelo deve ter em conta o domínio de aplicação. Em contextos biomédicos e farmacêuticos, modelos treinados especificamente nesse tipo de linguagem tendem a produzir representações mais adequadas do que modelos genéricos, uma vez que capturam melhor a terminologia clínica e as relações semânticas específicas do domínio.

2.3.3 - Bases de dados vetoriais

Após a conversão dos *chunks* em *embeddings*, estes precisam de ser armazenados de forma eficiente para permitir recuperação rápida por similaridade semântica. É para este propósito que existem as bases de dados vetoriais, sistemas de armazenamento otimizados para indexar e consultar grandes volumes de vetores de elevada dimensionalidade.

Ao contrário das bases de dados relacionais tradicionais, que organizam a informação em tabelas e respondem a *queries* exatas, as bases de dados vetoriais respondem a *queries* por similaridade, dado um vetor de consulta, o sistema devolve os vetores mais próximos no espaço semântico, tipicamente utilizando métricas como a similaridade de cosseno ou a distância euclidiana. Esta capacidade de recuperação aproximada por vizinhança é designada por Approximate Nearest Neighbor (ANN) e permite pesquisar eficientemente em coleções com milhões de vetores em tempo reduzido.

Para além do vetor em si, as bases de dados vetoriais permitem armazenar metadados associados a cada *chunk*, como o título do documento de origem, a data de publicação ou o número de página, que podem ser utilizados para filtrar os resultados da recuperação antes ou depois da pesquisa vetorial. Esta combinação de pesquisa semântica com filtragem por metadados é particularmente útil em domínios como o farmacêutico, onde pode ser necessário restringir a recuperação a documentos de um determinado tipo, como orientações clínicas ou bulas de medicamentos.

Existem várias soluções disponíveis, tanto código aberto como comerciais. Entre as mais utilizadas em sistemas RAG destacam-se o Chroma, o Qdrant, o Weaviate e o FAISS. Cada uma apresenta características distintas em termos de escalabilidade, suporte a metadados, velocidade de indexação e facilidade de integração com *frameworks* de desenvolvimento como o LangChain e o LlamaIndex. A escolha da base de dados vetorial deve ser guiada pelos requisitos do sistema, nomeadamente o volume de documentos, a necessidade de persistência e os recursos computacionais disponíveis.

2.4 - IA no Domínio Farmacêutico

A aplicação de inteligência artificial no domínio farmacêutico e da saúde tem crescido de forma significativa nos últimos anos, impulsionada pela disponibilidade de grandes volumes de dados clínicos e pelos avanços nos modelos de linguagem. Este domínio apresenta características particulares que tornam a adoção de IA simultaneamente mais promissora e mais exigente do que noutras áreas. A precisão da informação tem implicações diretas na segurança do doente, o vocabulário é altamente especializado e a informação está frequentemente dispersa por múltiplos documentos técnicos, orientações e regulamentos em constante atualização.

2.4.1 - Aplicações de IA em Saúde

A inteligência artificial tem sido aplicada em saúde em diversas vertentes, desde o diagnóstico assistido por imagem até à análise de registos clínicos eletrónicos e à geração automática de relatórios médicos. Uma das aplicações mais relevantes para o presente projeto são os sistemas de suporte à decisão clínica (Clinical Decision Support Systems, CDSS), que apoiam profissionais de saúde na tomada de decisões através de recomendações baseadas em evidência. No contexto farmacêutico em particular, os LLMs têm demonstrado capacidade para responder a questões clínicas, resumir literatura científica e apoiar decisões terapêuticas, surgindo como uma abordagem promissora para o desenvolvimento de CDSS baseados em linguagem natural.

No entanto, a utilização de LLMs em saúde levanta desafios importantes. O fenómeno de alucinação é particularmente crítico neste contexto, uma resposta incorreta sobre dosagem, interações medicamentosas ou contraindicações pode ter consequências graves para o doente. Acresce que o conhecimento farmacêutico evolui constantemente, com novas aprovações de medicamentos, atualizações de orientações e alertas de segurança a serem publicados regularmente, o que torna os modelos com conhecimento estático rapidamente desatualizados.

A estes desafios somam-se questões regulatórias e de privacidade. Em contextos clínicos, os dados dos doentes estão sujeitos a regulamentação estrita, o que limita a utilização de sistemas baseados em nuvem e exige soluções que garantam a confidencialidade da informação. Esta realidade tem impulsionado o interesse em sistemas de IA que possam ser executados localmente, sem envio de dados para servidores externos, e que sejam auditáveis e rastreáveis nas suas respostas.

2.4.2 - RAG Aplicado à Farmácia

Face aos desafios descritos anteriormente, o paradigma RAG surge como uma resposta particularmente adequada ao domínio farmacêutico. Ao permitir que o modelo aceda a documentação atualizada no momento da consulta, o RAG resolve simultaneamente o problema do conhecimento desatualizado e o da rastreabilidade das respostas, dois dos principais obstáculos à adoção de LLMs em contextos clínicos. A Figura 5 ilustra este processo aplicado ao domínio farmacêutico.




Figura 5 - Pipeline de um sistema RAG aplicado ao domínio farmacêutico

A documentação farmacêutica apresenta características que tornam a sua integração em sistemas RAG particularmente exigente. Bulas de medicamentos, fichas técnicas, orientações clínicas e regulamentos são documentos altamente estruturados, com secções específicas, terminologia técnica densa e conteúdo que varia significativamente entre tipos de documento. Esta heterogeneidade dificulta a segmentação e a recuperação, exigindo estratégias de *chunking* e modelos de *embedding* capazes de capturar adequadamente o significado de termos clínicos e farmacológicos. Um modelo de *embedding* genérico, treinado predominantemente em texto de uso geral, pode não reconhecer que "efeito antipirético" e "redução da febre" representam o mesmo conceito num contexto farmacêutico.

A investigação recente demonstra que sistemas RAG construídos sobre documentação farmacêutica estruturada conseguem melhorar significativamente a qualidade das respostas em tarefas de suporte à decisão clínica, face a LLMs genéricos sem mecanismos de recuperação. No entanto, a maioria dos sistemas desenvolvidos até ao momento recorre a bases de conhecimento públicas em inglês, com modelos de *embedding* e LLMs otimizados para essa língua. Esta dependência do inglês representa uma limitação relevante para contextos como o português, onde a terminologia farmacêutica, os regulamentos do INFARMED e as orientações nacionais seguem convenções linguísticas próprias que os modelos genéricos podem não representar adequadamente. O desenvolvimento de sistemas RAG adaptados ao contexto farmacêutico português constitui, assim, uma lacuna identificada na literatura e o ponto de partida do presente projeto. Os estudos que sustentam estas conclusões são analisados em detalhe no Capítulo 3.

2.4.3 - Enquadramento Regulatório

A implementação de sistemas de inteligência artificial no domínio farmacêutico está sujeita a um conjunto de obrigações regulatórias que condicionam o seu *design*, desenvolvimento e disponibilização. O presente projeto enquadra-se em três instrumentos regulatórios principais: o Regulamento Geral sobre a Proteção de Dados, o EU AI Act e as orientações do INFARMED.

Regulamento Geral sobre a Proteção de Dados (RGPD)

O Regulamento Geral sobre a Proteção de Dados (RGPD, Regulamento UE 2016/679) constitui o quadro legal europeu para o tratamento de dados pessoais e aplica-se a qualquer sistema que processe informação relativa a pessoas singulares. O RGPD classifica os dados de saúde como uma categoria especial de dados pessoais, sujeita a proteção reforçada e cujo tratamento é, em regra, proibido salvo mediante consentimento explícito ou enquadramento legal específico.

Um dos princípios centrais do RGPD com impacto direto no *design* de sistemas de IA é o *privacy by design*, que estabelece que a proteção de dados deve ser integrada desde a conceção do sistema, e não tratada como um requisito secundário ou adicionado a posteriori. Complementarmente, o princípio de *privacy by default* determina que as configurações padrão do sistema devem ser as mais protetoras de privacidade possível. No contexto do presente projeto, estes princípios implicam minimizar a recolha e retenção de dados de utilização, não armazenar o histórico de *queries* por defeito, implementar controlos de acesso baseados em perfis e garantir que qualquer dado processado é estritamente necessário ao funcionamento do sistema. O RGPD estabelece ainda o direito à explicação das decisões automatizadas, o que reforça a necessidade de rastreabilidade e citação de fontes nas respostas geradas pelo sistema.

EU AI Act

O EU AI Act (Regulamento UE 2024/1689) é o primeiro quadro regulatório abrangente para sistemas de inteligência artificial a nível europeu, adotando uma abordagem baseada no risco que classifica os sistemas de IA em quatro categorias: risco inaceitável, alto risco, risco limitado e risco mínimo. Os sistemas de IA aplicados à saúde, incluindo sistemas de suporte à decisão clínica e farmacêutica, são classificados como sistemas de alto risco, estando sujeitos a um conjunto de obrigações específicas antes e durante a sua colocação no mercado.

Para sistemas de alto risco, o EU AI Act impõe requisitos em várias dimensões. O Artigo 9.º estabelece a obrigação de implementar um sistema de gestão de risco ao longo de todo o ciclo de vida do sistema. O Artigo 13.º obriga a que os sistemas forneçam informação suficiente e compreensível para que os utilizadores entendam as capacidades e limitações do sistema, incluindo o nível de precisão esperado e os cenários em que o sistema pode produzir resultados incorretos. O Artigo 14.º determina que os sistemas de alto risco devem ser concebidos de forma a permitir supervisão humana efetiva, incluindo a capacidade de interromper o sistema ou anular as suas decisões. O Artigo 17.º exige a manutenção de documentação técnica detalhada que permita avaliar a conformidade do sistema. Estas obrigações têm implicações diretas no *design* do sistema desenvolvido, nomeadamente na necessidade de identificar claramente a natureza artificial do sistema, citar as fontes utilizadas em cada resposta, apresentar avisos de responsabilidade explícitos sobre as limitações das respostas geradas e implementar mecanismos de registo de auditoria.

INFARMED

O INFARMED, Autoridade Nacional do Medicamento e Produtos de Saúde, I.P., é a entidade regulatória portuguesa responsável pela avaliação, autorização, disciplina e controlo da produção, distribuição, comercialização e utilização de medicamentos para uso humano e produtos de saúde. Enquanto autoridade competente nacional, o INFARMED emite normas, orientações e circulares informativas que constituem referência obrigatória para farmacêuticos e técnicos de farmácia no exercício das suas funções.

No contexto do presente projeto, o INFARMED é relevante em duas dimensões. Em primeiro lugar, como fonte de documentação farmacêutica oficial, as normas, orientações terapêuticas e informação sobre medicamentos autorizados em Portugal disponibilizadas pelo INFARMED constituem parte do corpus documental do sistema, garantindo que as respostas geradas são fundamentadas em fontes regulatoriamente reconhecidas e atualizadas. Em segundo lugar, como enquadramento regulatório para o uso de sistemas de informação em contexto farmacêutico, a utilização de ferramentas digitais de suporte à decisão em farmácia deve ser compatível com as boas práticas farmacêuticas definidas pelo INFARMED, que estabelecem que o farmacêutico mantém sempre a responsabilidade clínica pelas decisões tomadas, independentemente das ferramentas de apoio utilizadas. Esta responsabilidade intransferível do profissional de saúde reforça a importância dos mecanismos de aviso de responsabilidade e supervisão humana implementados no sistema.

3 - Estado da Arte

3.1 - Metodologia de Revisão Sistemática

A revisão de literatura apresentada neste capítulo seguiu a metodologia PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*), uma abordagem estruturada e amplamente reconhecida na comunidade científica para a condução de revisões sistemáticas. A adoção desta metodologia visa garantir a transparência, reprodutibilidade e rigor do processo de seleção dos estudos revistos.

3.1.1 - Perguntas de Investigação

Para orientar a pesquisa bibliográfica, foram definidas uma pergunta de investigação principal e três perguntas secundárias, alinhadas com os objetivos do projeto.

Pergunta principal: *«Que abordagens baseadas em RAG têm sido aplicadas ao suporte à decisão em contexto farmacêutico?»*

As perguntas secundárias, formuladas para aprofundar diferentes dimensões do tema, são as seguintes:

S1: *«Que arquiteturas RAG existem e quais as suas características?»*

S2: *«Que modelos de embedding, estratégias de ing e bases de dados vetoriais são mais utilizados em sistemas RAG?»*

S3: *«Que regulamentações e especificidades do domínio farmacêutico devem ser consideradas num sistema de IA para saúde?»*

3.1.2 - Estratégia de Pesquisa

A pesquisa bibliográfica foi realizada através da plataforma *Consensus* (consensus.app), um motor de pesquisa académico baseado em inteligência artificial que agrega resultados de diversas bases de dados científicas. A gestão das referências foi efetuada com recurso ao *Mendeley*, uma ferramenta de gestão de referências bibliográficas.

As pesquisas foram conduzidas separadamente para cada pergunta de investigação secundária (S1, S2 e S3), utilizando termos de pesquisa específicos e adequados a cada temática. Foram considerados artigos publicados entre 2020 e 2026, redigidos em inglês ou português.

3.1.3 - Critérios de Seleção

A seleção dos artigos foi orientada por critérios de inclusão e exclusão previamente definidos, de forma a assegurar a relevância e a qualidade dos estudos revistos.

Critérios de inclusão:

- Artigos sobre RAG, LLMs ou sistemas de recuperação de informação;
- Artigos sobre inteligência artificial aplicada à saúde ou farmácia;
- Artigos sobre *embeddings*, bases de dados vetoriais ou NLP biomédico;
- Publicados entre 2020 e 2026;
- Redigidos em inglês ou português;
- Com revisão por pares ou pré-publicações publicados em repositórios reconhecidos (e.g., arXiv, medRxiv).

Critérios de exclusão:

- Artigos publicados antes de 2020;
- Artigos sem relação com NLP, LLMs ou recuperação de informação;
- Artigos noutros idiomas que não inglês ou português;
- Artigos duplicados entre subsecções;
- Artigos sem abstract disponível;
- Artigos de opinião sem base empírica;
- Artigos cujo foco principal é regulação de IA sem abordagem técnica de RAG ou NLP;
- Artigos redundantes com outros já incluídos, avaliado após análise detalhada do conteúdo técnico dos artigos pré-selecionados;
- Artigos fora do âmbito do projeto.

3.1.4 - Processo de Seleção e Resultados

O processo de seleção seguiu as três fases previstas pela metodologia PRISMA: identificação, triagem e inclusão. Na fase de identificação, foram recolhidos 51 artigos através das pesquisas realizadas nas três subsecções temáticas. Após a remoção de 5 artigos duplicados, restaram 46 artigos para triagem. A fase de triagem consistiu na leitura dos títulos e abstracts, seguida de leitura integral dos artigos pré-selecionados, resultando na exclusão de 32 artigos por não cumprirem os critérios de inclusão ou por redundância temática com outros estudos incluídos. No total, foram incluídos 14 artigos na revisão sistemática.

A Tabela 1 apresenta a distribuição dos artigos por subsecção temática ao longo do processo de seleção.

Subsecção	Identificados	Duplicados	Excluídos	Incluídos
Arquiteturas RAG	20	0	14	6
<i>Embeddings</i> e Vector DBs	14	4	8	2
Farmácia e Regulação	17	1	10	6
Total	51	5	32	14

Tabela 1 - Resultados do processo de seleção PRISMA por subsecção

A Figura 6 apresenta o fluxograma PRISMA completo, ilustrando as diferentes fases do processo de seleção. Este fluxograma foi elaborado com base no modelo disponibilizado em prisma-statement.org, utilizando o template para revisões sistemáticas com pesquisa apenas em bases de dados.




Figura 6 - Fluxograma PRISMA do processo de seleção de artigos

3.2 – Síntese dos Estudos Incluídos

A tabela seguinte apresenta os 14 artigos incluídos na revisão sistemática, com indicação do tema principal e da respetiva contribuição para o projeto.

Referência	Tema	Contribuição para o projeto
Lewis et al. (2020)	Fundamentos de RAG	Introduz o paradigma RAG original, combinando memória paramétrica (modelo seq2seq pré-treinado) com memória não-paramétrica (índice vetorial denso). Constitui a base conceptual sobre a qual o sistema proposto assenta, definindo os princípios de recuperação e geração que orientam toda a arquitetura desenvolvida.

Referência	Tema	Contribuição para o projeto
Gao et al. (2024)	Arquiteturas RAG	Propõe uma taxonomia detalhada dos paradigmas RAG, Naive, Advanced e Modular, e analisa as técnicas de recuperação, augmentação e geração em cada um. Fundamenta diretamente as escolhas arquiteturais do sistema desenvolvido, nomeadamente a seleção do paradigma e dos componentes do <i>pipeline</i> .
Kim et al. (2025)	RAG farmacêutico	Apresenta o QA-RAG, um <i>framework</i> RAG com mecanismo de recuperação dual aplicado à conformidade regulatória farmacêutica, superando o RAG convencional em precisão, <i>recall</i> e <i>F1-score</i> . É o estudo mais diretamente alinhado com o objetivo do projeto, demonstrando que abordagens RAG especializadas respondem melhor às especificidades do domínio farmacêutico do que sistemas genéricos.
Borishetty et al. (2025)	RAG farmacogenómico	Desenvolve o PGxRAG, um assistente RAG construído sobre orientações farmacogenómicas (CPIC, FDA, KNMP), atingindo 95.1% de precisão com GPT-4o. Valida diretamente a abordagem adotada no projeto, demonstrando que a integração de RAG com bases de conhecimento farmacêutico estruturadas produz resultados clinicamente relevantes.
Liu et al. (2025)	RAG biomédico	Meta-análise de 20 estudos que quantifica o impacto do RAG em aplicações biomédicas, reportando um rácio de probabilidade de 1.35 face a LLMs sem RAG. Fornece evidência empírica que justifica a adoção de RAG como abordagem central do projeto e serve de referência para a avaliação dos resultados obtidos.
Xiong et al. (2024)	Avaliação RAG médico	Introduz a referência comparativa MIRAGE com 7663 questões médicas e o toolkit MEDRAG, avaliando 41 combinações de corpora, recuperação e LLMs. Fornece referências de desempenho comparativas aplicáveis à fase de avaliação do sistema, bem como orientações sobre as melhores combinações de componentes em contexto médico.
Es et al. (2023)	Avaliação de RAG	Apresenta o <i>framework</i> RAGAS para avaliação automática de <i>pipelines</i> RAG sem necessidade de anotações humanas, cobrindo dimensões como fidelidade, relevância e qualidade de recuperação. É diretamente aplicável à fase de avaliação do sistema desenvolvido, permitindo uma avaliação sistemática e reproduzível do <i>pipeline</i> implementado.
Bossenz et al. (2025)	<i>Chunking embeddings</i> e	Avalia oito modelos de <i>embedding</i> e diversas configurações de <i>chunking</i> num sistema RAG hospitalar com 1219 documentos reais. Orienta decisões práticas de implementação do projeto, nomeadamente a seleção do modelo de <i>embedding</i> e dos parâmetros de <i>chunking</i> mais adequados ao corpus farmacêutico utilizado.

Referência	Tema	Contribuição para o projeto
Sarathi et al. (2024)	Chunking avançado	Propõe o RAPTOR, uma estratégia de <i>chunking</i> hierárquico por sumarização recursiva que constrói uma árvore de representações a diferentes níveis de abstração. Contextualiza uma abordagem alternativa ao <i>chunking</i> fixo, relevante caso o sistema necessite de processar documentos farmacêuticos extensos com estrutura complexa.
Liu et al. (2024)	RAG clínico	Revisão de âmbito sobre implementações técnicas de RAG em medicina, identificando lacunas como a dependência de dados públicos, modelos de <i>embedding</i> centrados no inglês e avaliação insuficiente de viés e segurança. Enquadra o contexto clínico do projeto e identifica limitações do estado atual que o sistema procura endereçar.
Bunnell et al. (2025)	Ética e transparência	Revisão sobre dimensões éticas, viés e transparência em sistemas RAG para saúde, analisando implicações de equidade, explicabilidade e responsabilidade. Contextualiza as considerações éticas e as limitações que devem ser reconhecidas no desenvolvimento e avaliação do sistema proposto.
Singh et al. (2025)	Agentic RAG	Apresenta a evolução do paradigma RAG para sistemas com agentes autônomos, incorporando padrões de reflexão, planeamento e colaboração multi-agente. Contextualiza a direção mais recente da área, sendo relevante sobretudo para a identificação de trabalho futuro.
Peng et al. (2024)	GraphRAG	Analisa a integração de estruturas de grafo em sistemas RAG, permitindo recuperação relacional que captura dependências entre entidades. Contextualiza uma variante arquitetural relevante para domínios com conhecimento estruturado, como o farmacêutico.
Guo et al. (2024)	LightRAG	Demonstra uma implementação prática de GraphRAG com sistema de recuperação a dois níveis e atualização incremental de dados. Complementa o enquadramento de GraphRAG com evidência empírica de ganhos de eficiência em cenários reais.

Tabela 2 - Síntese dos estudos incluídos e contribuição para o projeto

3.3 Análise Crítica

A revisão sistemática realizada permite identificar tendências relevantes e lacunas no estado atual da investigação sobre sistemas RAG aplicados ao domínio biomédico e farmacêutico.

No que diz respeito às arquiteturas RAG, a literatura evidencia uma evolução clara desde o paradigma Naive RAG até abordagens mais sofisticadas, como o Advanced RAG, o Modular RAG e, mais recentemente, o Agentic RAG. Esta progressão reflete uma preocupação crescente com

a qualidade da recuperação, a redução de alucinações e a adaptabilidade a domínios específicos. Contudo, a maioria dos estudos de arquitetura é conduzida em contextos genéricos, sem validação em domínios clínicos ou farmacêuticos, o que limita a transferência direta das conclusões para o presente projeto.

No domínio da saúde, a evidência empírica é promissora. A meta-análise de Liu et al. (2025) demonstra que a integração de RAG melhora significativamente o desempenho de LLMs em tarefas biomédicas, com um rácio de probabilidade de 1.35 face a modelos sem recuperação. Estudos como o PGxRAG (Borishetty et al., 2025) e o QA-RAG (Kim et al., 2025) validam a aplicabilidade desta abordagem em contextos farmacêuticos concretos, atingindo níveis de precisão compatíveis com utilização clínica. No entanto, a maioria destes sistemas recorre a bases de conhecimento públicas em inglês, o que representa uma limitação relevante para contextos multilingues ou com documentação proprietária.

A avaliação de sistemas RAG é outra área em desenvolvimento. *Frameworks* como o RAGAS (Es et al., 2023) e referências comparativas como o MIRAGE (Xiong et al., 2024) oferecem metodologias reproduzíveis, mas carecem de métricas específicas para o domínio farmacêutico, nomeadamente indicadores de segurança clínica e rastreabilidade das respostas geradas.

Face a este panorama, o presente projeto representa uma contribuição relevante por razões concretas que decorrem diretamente das lacunas identificadas. A dependência da maioria dos sistemas RAG biomédicos de bases de conhecimento em inglês não é uma limitação menor, significa que profissionais de saúde portugueses não têm acesso a sistemas que compreendam a terminologia farmacêutica nacional, as convenções linguísticas das bulas portuguesas ou as normas específicas do INFARMED. Um sistema que opere sobre documentação farmacêutica oficial portuguesa em língua portuguesa não é apenas uma adaptação linguística superficial, é uma condição necessária para que as respostas geradas sejam clinicamente utilizáveis neste contexto regulatório específico.

A ausência de conformidade regulatória nos sistemas existentes é igualmente problemática em contexto europeu: um sistema de suporte à decisão clínica que não respeite os requisitos do EU AI Act para sistemas de alto risco não pode ser legalmente implementado em Portugal, independentemente da sua qualidade técnica. O presente sistema integra desde a sua conceção os requisitos de rastreabilidade, supervisão humana e transparência exigidos, tornando-o adequado para utilização real em contexto farmacêutico nacional.

Por fim, o desenvolvimento de um sistema RAG especializado, construído sobre documentação farmacêutica oficial portuguesa e avaliado em cenários de utilização real neste contexto regulatório, não tem precedente direto na literatura revista, o que confere ao trabalho carácter exploratório com potencial de contribuição original para a área, nomeadamente no que respeita à demonstração da viabilidade e eficácia desta abordagem em línguas e contextos regulatórios sub-representados na investigação atual.

4 - Desenvolvimento do Sistema

4.1 - Requisitos

4.1.1 - Requisitos Funcionais

Os requisitos funcionais descrevem as funcionalidades que o sistema deve disponibilizar aos seus utilizadores. A Tabela 3 apresenta os requisitos funcionais identificados.

ID	Designação	Descrição
RF01	Ingestão de documentos	O sistema deve permitir carregar e processar documentos farmacêuticos em formato PDF, incluindo bulas, monografias, guias terapêuticos, formulários hospitalares e normas do INFARMED.
RF02	Indexação do corpus	O sistema deve segmentar os documentos em <i>chunks</i> , gerar <i>embeddings</i> e armazená-los numa base de dados vetorial para posterior recuperação.
RF03	Recuperação por similaridade semântica	O sistema deve, dado uma entrada do utilizador, recuperar os <i>chunks</i> mais relevantes da base de dados vetorial com base em similaridade semântica.
RF04	Geração de respostas fundamentadas	O sistema deve gerar respostas em linguagem natural com base nos <i>chunks</i> recuperados, incluindo citação explícita da fonte, documento de origem e secção ou página quando disponível.
RF05	Validação de entrada	O sistema deve validar se a questão colocada pertence ao domínio farmacêutico e rejeitar <i>queries</i> fora do âmbito ou que contenham tentativas de <i>prompt injection</i> .
RF06	Validação do contexto recuperado	O sistema deve verificar a relevância mínima dos <i>chunks</i> recuperados e alertar ou recusar a geração quando o contexto for insuficiente ou a similaridade for abaixo de um limiar definido.
RF07	Gestão de situações de baixa confiança	O sistema deve detetar respostas com baixo grau de fidelidade ao contexto e, consoante o grau de incerteza, sinalizar ao utilizador com um aviso explícito ou recusar gerar uma resposta, apresentando uma mensagem clara a indicar que a questão não pôde ser respondida com base na documentação disponível e que deve ser consultado um profissional de saúde qualificado.
RF08	Controlo de acesso por perfis	O sistema deve suportar dois perfis de utilizador: utilizador (farmacêutico ou técnico de farmácia que realiza consultas) e administrador (responsável pela gestão de documentos, configurações e monitorização do sistema), com permissões distintas de acesso às funcionalidades.

ID	Designação	Descrição
RF09	Registo de auditoria	O sistema deve registar todas as <i>queries</i> , documentos recuperados e respostas geradas, com marca temporal e identificador do utilizador, para fins de rastreabilidade e auditoria.
RF10	Interface de consulta	O sistema deve disponibilizar uma interface simples que permita ao utilizador colocar questões e visualizar as respostas geradas juntamente com as fontes utilizadas.
RF11	Gestão de documentos	O perfil administrador deve poder adicionar, remover e atualizar documentos no corpus documental, com reindexação automática após qualquer alteração.
RF12	Filtragem por tipo de documento	O sistema deve permitir ao utilizador restringir a pesquisa a um tipo específico de documento, como bulas, monografias, guias terapêuticos ou normas do INFARMED, de forma a tornar a recuperação mais precisa e contextualizada.
RF13	Transparência com o utilizador	O sistema deve informar o utilizador de forma clara que está a interagir com um sistema de inteligência artificial e apresentar um aviso de responsabilidade explícito em todas as respostas indicando que a informação gerada não substitui o aconselhamento de um profissional de saúde qualificado.
RF14	Recuperação híbrida	O sistema deve suportar recuperação híbrida, combinando pesquisa por similaridade semântica com pesquisa por palavra-chave exata, de forma a melhorar a precisão na identificação de documentos relevantes, nomeadamente em consultas que incluam nomes específicos de medicamentos, princípios ativos ou códigos de referência.

Tabela 3 - Requisitos funcionais do sistema

4.1.2 - Requisitos Não Funcionais

Os requisitos não funcionais definem as condições de qualidade e restrições sob as quais o sistema deve operar. A Tabela 4 apresenta os requisitos não funcionais identificados.

ID	Designação	Descrição
RNF01	Desempenho	O sistema deve gerar respostas em tempo adequado ao contexto de utilização clínica, com um tempo de resposta máximo de 10 segundos para consultas típicas.
RNF02	Fiabilidade	O sistema deve garantir que todas as respostas geradas são fundamentadas nos documentos indexados, não introduzindo informação não suportada pelo contexto recuperado.

ID	Designação	Descrição
RNF03	Rastreabilidade	Todas as respostas devem incluir citação explícita da fonte documental utilizada, indicando o documento de origem e, quando disponível, a secção ou página, permitindo ao utilizador verificar a informação no documento original.
RNF04	Privacidade e proteção de dados	O sistema deve ser desenvolvido segundo os princípios de <i>privacy by design</i> e <i>privacy by default</i> , minimizando a recolha e retenção de dados pessoais, em conformidade com o RGPD, conforme descrito na secção 2.4.3.
RNF05	Segurança	O sistema deve implementar mecanismos de proteção contra <i>prompt injection</i> e acesso não autorizado, garantindo a integridade das respostas geradas.
RNF06	Manutenibilidade	O corpus documental deve poder ser atualizado de forma independente, sem necessidade de modificar ou re-treinar o modelo generativo.
RNF07	Portabilidade	O sistema deve ser empacotado com Docker, permitindo a sua disponibilização em diferentes ambientes de forma reprodutível e documentada.
RNF08	Usabilidade	A interface de consulta deve ser suficientemente simples e intuitiva para ser utilizada por profissionais de saúde sem formação técnica em sistemas de IA.
RNF09	Conformidade regulatória	O sistema deve estar alinhado com os requisitos do EU AI Act para sistemas de IA de alto risco, nomeadamente em termos de transparência, auditabilidade, rastreabilidade e supervisão humana, garantindo que os utilizadores são informados da natureza do sistema com que interagem, conforme descrito na secção 2.4.3.
RNF10	Encriptação	O sistema deve garantir encriptação dos dados em repouso e em trânsito, assegurando a confidencialidade da informação processada, em conformidade com o RGPD, conforme descrito na secção 2.4.3.

Tabela 4 - Requisitos não funcionais do sistema

4.2 - Arquitetura do Sistema

4.2.1 - Decisão Arquitetural

A definição da arquitetura do sistema foi precedida de uma análise das principais abordagens RAG disponíveis na literatura, avaliadas face aos requisitos funcionais e não funcionais definidos na secção 4.1 e às especificidades do domínio farmacêutico.

O Naive RAG foi considerado e rejeitado como arquitetura base por apresentar limitações significativas para o contexto em causa: a dependência de uma única etapa de recuperação por similaridade semântica é insuficiente para documentos farmacêuticos com terminologia técnica específica, onde a pesquisa por nome exato de medicamento ou princípio ativo é frequente. Adicionalmente, a ausência de mecanismos de validação do contexto recuperado e de mecanismos de segurança torna esta arquitetura inadequada para um sistema de alto risco.

O GraphRAG foi identificado como uma evolução promissora para este domínio, dado que o conhecimento farmacêutico é intrinsecamente relacional, medicamentos têm interações, contraindicações e grupos farmacológicos que um grafo de conhecimento capturaria de forma mais precisa do que a recuperação vetorial. No entanto, a construção e manutenção de um grafo farmacológico de qualidade constitui um projeto de engenharia significativo, fora do âmbito do presente trabalho.

O Agentic RAG foi igualmente considerado e rejeitado para o contexto atual. Embora ofereça capacidades de raciocínio multi-passo relevantes para consultas complexas, a sua imprevisibilidade de comportamento e a dificuldade de auditabilidade são incompatíveis com os requisitos de transparência e supervisão humana impostos pelo EU AI Act para sistemas de alto risco (RNF09).

O Self-RAG, que introduz a capacidade de o próprio modelo decidir quando recuperar informação adicional e avaliar a utilidade do contexto obtido, foi considerado fora do âmbito do presente projeto por exigir *fine-tuning* especializado do modelo generativo, o que ultrapassa os recursos disponíveis.

A arquitetura selecionada combina os paradigmas **Advanced RAG**, **Modular RAG** e **CRA**. Do Advanced RAG incorporam-se mecanismos de recuperação híbrida, *reranking* e validação do contexto recuperado, que melhoram a precisão da recuperação em documentos técnicos farmacêuticos. Esta decisão é suportada empiricamente pelo trabalho de Kim et al. (2025), que demonstrou que um mecanismo de recuperação a duas vias, combinando pesquisa semântica

com pesquisa baseada na *query* original, supera o RAG convencional em precisão, *recall* e *F1-score* em contexto farmacêutico. Do Modular RAG adota-se a organização do sistema em módulos independentes e substituíveis, o que está alinhado com o requisito de manutenibilidade (RNF06) e permite a integração dos mecanismos de segurança como módulos autônomos no *pipeline*. Do CRAG adota-se o mecanismo de avaliação da qualidade do contexto recuperado e de ação corretiva quando essa qualidade é considerada insuficiente, o *pipeline* de consulta avalia a relevância dos *chunks* recuperados e, caso esta seja abaixo do limiar definido, reformula a *query* e desencadeia uma nova recuperação antes de gerar a resposta. Estes mecanismos estão diretamente alinhados com os requisitos RF06 e RF07 e reforçam a robustez do sistema em situações onde a documentação disponível não cobre adequadamente a questão colocada.

A abordagem de construir a base de conhecimento sobre documentação farmacêutica oficial estruturada segue os princípios demonstrados pelo PGxRAG (Borishetty et al., 2025), que mostrou que sistemas RAG construídos sobre orientações clínicas estruturadas atingem níveis de precisão clinicamente relevantes. No presente projeto, esta abordagem é aplicada à documentação farmacêutica portuguesa, nomeadamente bulas, monografias e normas do INFARMED.

Arquitetura	Decisão	Razão
Naive RAG	Rejeitada	Sem recuperação híbrida nem mecanismos de segurança
Advanced RAG	Adotada	Recuperação híbrida, <i>reranking</i> , validação
Modular RAG	Adotada	Modularidade e manutenibilidade
CRAG	Adotada	Avaliação e correção da recuperação
GraphRAG	Rejeitada	Complexidade de construção do grafo
Agentic RAG	Rejeitada	Imprevisibilidade, incompatível com EU AI Act
Self-RAG	Rejeitada	Exige <i>fine-tuning</i>

Tabela 5 - Comparação das arquiteturas RAG consideradas

4.2.2 – Visão Geral do Sistema

O sistema está organizado em três camadas funcionais principais, conforme ilustrado na Figura 7.

A primeira camada corresponde à camada de entrada e controlo, responsável por receber os pedidos dos utilizadores através de uma API REST e por validar tanto a entrada como a saída através dos mecanismos de segurança.

A segunda camada corresponde à camada de orquestração, onde o *pipeline* RAG coordena a recuperação de contexto relevante da base de dados vetorial, a geração de *embeddings* e a produção da resposta pelo modelo generativo.

A terceira camada corresponde à base de conhecimento, constituída pelo corpus documental de documentação farmacêutica oficial, indexado e disponível para recuperação por similaridade semântica e por palavra-chave.

Transversalmente a estas camadas, o sistema mantém um registo de auditoria de todas as interações, em conformidade com os requisitos de rastreabilidade definidos no RF10 e RNF09.




Figura 7 - Arquitetura geral do sistema

4.2.3 - Pipeline de Ingestão

O *pipeline* de ingestão é responsável pelo processamento e indexação da documentação farmacêutica que constitui a base de conhecimento do sistema. Este *pipeline* opera de forma *offline* e independente do *pipeline* de consulta, sendo executado pelo administrador sempre que são adicionados, removidos ou atualizados documentos no corpus, desencadeando uma reindexação automática conforme definido no RF12.

O processo inicia-se com a extração de conteúdo dos documentos PDF. A documentação farmacêutica apresenta dois tipos de conteúdo estruturalmente distintos que requerem tratamento diferenciado: texto corrido, como descrições, indicações terapêuticas e contraindicações, e tabelas, como esquemas de posologia, parâmetros farmacocinéticos e perfis de interações medicamentosas. Para o texto corrido é utilizado o PyMuPDF, que oferece extração rápida e limpa de texto nativo. Para as tabelas é utilizado o pdfplumber, que preserva a estrutura tabular e converte o conteúdo para texto formatado antes do *chunking*, garantindo que a informação estruturada não é perdida ou distorcida no processo de segmentação.

Após a extração, o texto é submetido a um processo de limpeza e normalização, que inclui a remoção de cabeçalhos e rodapés repetidos, normalização de espaçamentos e tratamento de caracteres especiais, de forma a garantir a qualidade do conteúdo indexado.

O texto limpo é então segmentado em *chunks* de 1000 *tokens* com uma sobreposição de 200 *tokens* entre *chunks* consecutivos. A sobreposição garante a continuidade semântica entre segmentos adjacentes, reduzindo a probabilidade de perda de informação relevante nas fronteiras entre *chunks*. O tamanho e a sobreposição dos *chunks* são parâmetros configuráveis, permitindo a sua otimização em função das características específicas do corpus farmacêutico, em linha com as recomendações de Bossenz et al. (2025) para documentação hospitalar de natureza semelhante.

A cada *chunk* são associados metadados estruturados que permitem a filtragem e rastreabilidade das respostas geradas: o tipo de documento, o nome do ficheiro de origem, a data de publicação, o número de página e a secção do documento a que o *chunk* pertence. Estes metadados são essenciais para a filtragem por tipo de documento (RF13), para a citação precisa das fontes nas respostas geradas (RF04) e para o alerta automático quando documentos têm mais de dois anos.

Por fim, cada *chunk* é convertido numa representação vetorial pelo modelo de *embedding* e o par vetor-metadados é armazenado na base de dados vetorial, onde fica disponível para recuperação durante o *pipeline* de consulta. A Figura 8 ilustra as etapas do *pipeline* de ingestão.




Figura 8 - Pipeline de ingestão

O *pipeline* de ingestão apresenta uma limitação conhecida relativamente ao conteúdo visual presente na documentação farmacêutica. Imagens de estruturas químicas, gráficos farmacocinéticos e outros elementos visuais não são processados pelo *pipeline* atual, sendo descartados durante a extração de texto. Esta limitação é considerada aceitável para o âmbito do presente projeto, uma vez que a informação clinicamente relevante para suporte à decisão farmacêutica, indicações, contraindicações, posologia e interações medicamentosas, está tipicamente disponível em formato textual nas bulas e orientações. O processamento de conteúdo visual especializado, nomeadamente através de modelos multimodais ou ferramentas de OCR químico, é identificado como direção de trabalho futuro.

4.2.4 - Pipeline de Consulta

O *pipeline* de consulta é responsável pelo processamento das questões colocadas pelos utilizadores em tempo real, desde a receção da entrada até à geração da resposta fundamentada. Este *pipeline* incorpora os mecanismos de Advanced RAG, Modular RAG e CRAG definidos na secção 4.2.1, operando de forma sequencial com pontos de controlo de qualidade em diferentes etapas.

O processo inicia-se com a receção da questão do utilizador pela API REST e a sua validação pelo mecanismo de segurança de entrada, que verifica se a questão pertence ao domínio farmacêutico e se não contém tentativas de *prompt injection*, conforme definido no RF05. Questões fora do âmbito ou maliciosas são rejeitadas nesta etapa, devolvendo ao utilizador uma mensagem informativa sem aceder ao *pipeline* de recuperação.

Após validação, a questão é convertida numa representação vetorial pelo modelo **Gemini Embedding 2**, sendo submetida simultaneamente a uma pesquisa por similaridade semântica e a uma pesquisa por palavra-chave na base de dados vetorial Qdrant. Esta recuperação híbrida, inspirada no mecanismo de recuperação a duas vias do QA-RAG (Kim et al., 2025), permite capturar tanto a intenção semântica da questão como termos técnicos específicos, como nomes de medicamentos ou princípios ativos, que poderiam não ser adequadamente capturados por pesquisa semântica isolada. São recuperados inicialmente os 10 *chunks* mais relevantes.

Os *chunks* recuperados são submetidos a um processo de *reranking* baseado em *LLM-as-Judge*, onde o Claude 3.5 Sonnet avalia a relevância de cada *chunk* face à questão original e seleciona os 3 *chunks* mais relevantes para construção do contexto. Este mecanismo de *reranking* reduz o ruído no contexto enviado ao modelo generativo e melhora a qualidade das respostas geradas.

A relevância do contexto selecionado é então avaliada face a um limiar mínimo definido, em conformidade com os princípios do CRAG. Se a relevância for considerada insuficiente, o sistema reformula a *query* e desencadeia uma nova recuperação antes de avançar para a geração. Se após a segunda recuperação o contexto continuar insuficiente, o sistema ativa o mecanismo de resposta em situações de baixa confiança definido no RF07, recusando gerar uma resposta e informando o utilizador de que a questão não pôde ser respondida com base na documentação disponível.

Quando o contexto é considerado suficiente, é construído um *prompt* enriquecido que combina a questão original com os *chunks* recuperados e respectivos metadados de fonte. O Claude 3.5 Sonnet gera então uma resposta em linguagem natural fundamentada exclusivamente no contexto fornecido, incluindo citação explícita da fonte, documento de origem, secção e página quando disponíveis, em conformidade com o RF04.

A resposta gerada é submetida ao mecanismo de segurança de saída, que verifica a fidelidade da resposta ao contexto recuperado e assegura a presença do aviso de responsabilidade obrigatório indicando que a informação gerada não substitui o aconselhamento de um profissional de saúde qualificado, conforme definido no RF14. A resposta validada é então devolvida ao utilizador através da API, e a interação é registada no log de auditoria com marca temporal e identificador do utilizador, em conformidade com o RF10. A Figura 9 ilustra as etapas do *pipeline* de consulta.




Figura 9 - Pipeline de consulta

4.2.5 - Mecanismos de Segurança

Os mecanismos de segurança constituem uma camada transversal do sistema, responsável por garantir que as interações respeitem os limites do domínio farmacêutico, que as respostas geradas sejam fiéis à documentação recuperada e que o sistema opere em conformidade com os requisitos de segurança e rastreabilidade definidos. A implementação de mecanismos de segurança é particularmente crítica num sistema de alto risco como o presente, onde respostas incorretas podem ter consequências diretas na segurança do doente. O sistema implementa quatro tipos de mecanismos de segurança, descritos de seguida.

Mecanismo de segurança de entrada

O mecanismo de segurança de entrada é o primeiro ponto de controlo do *pipeline* de consulta, aplicado antes de qualquer acesso à base de dados vetorial. Este mecanismo de segurança realiza duas verificações distintas. Em primeiro lugar, verifica se a questão colocada pertence ao domínio farmacêutico, questões sobre temas não relacionados com medicamentos, farmácia ou saúde são rejeitadas com uma mensagem informativa ao utilizador. Em segundo lugar, analisa a entrada em busca de padrões de *prompt injection*, ou seja, tentativas de manipular o comportamento do sistema através de instruções maliciosas embutidas na *query*. *Queries* que acionem este mecanismo são bloqueadas sem aceder ao *pipeline* de recuperação, em conformidade com o RF05.

Validação do contexto recuperado

Após a recuperação e *reranking* dos *chunks*, o sistema avalia a relevância do contexto selecionado face à questão colocada, em conformidade com os princípios do CRAG e os requisitos RF06 e RF07. Esta validação é realizada pelo Claude 3.5 Sonnet num papel de *LLM-as-Judge*, que atribui uma pontuação de relevância ao contexto recuperado. Se a pontuação for inferior ao limiar definido, o sistema desencadeia uma reformulação da *query* e uma nova recuperação. Se após a segunda tentativa o contexto continuar insuficiente, o sistema recusa gerar uma resposta e apresenta ao utilizador uma mensagem clara indicando que a questão não pôde ser respondida com base na documentação disponível e que deve ser consultado um profissional de saúde qualificado.

Mecanismo de segurança de saída

O mecanismo de segurança de saída é aplicado após a geração da resposta pelo Claude 3.5 Sonnet, antes de esta ser devolvida ao utilizador. Este mecanismo de segurança utiliza

novamente o Claude como *LLM-as-Judge* para verificar a fidelidade da resposta ao contexto recuperado, avaliando se a resposta se baseia exclusivamente na documentação fornecida e não introduz informação não suportada pelo contexto. Respostas com fidelidade abaixo do limiar definido são sinalizadas com um aviso explícito ao utilizador. Adicionalmente, este mecanismo de segurança assegura que todas as respostas incluem a citação da fonte utilizada e o aviso de responsabilidade obrigatório indicando que a informação gerada não substitui o aconselhamento de um profissional de saúde qualificado, em conformidade com o RF14.

Registo de auditoria

Transversalmente a todo o *pipeline*, o sistema mantém um registo imutável de todas as interações, incluindo a *query* original, os *chunks* recuperados, a resposta gerada, as pontuações de relevância e fidelidade, a marca temporal e o identificador pseudonimizado do utilizador. Este registo serve simultaneamente propósitos de rastreabilidade, auditoria e conformidade regulatória, em conformidade com o RF10, o RNF09 e os requisitos de registo do EU AI Act (Artigo 12.º). Os registos são conservados por um período definido e acessíveis apenas ao administrador do sistema, em conformidade com o RNF04.

4.3 - Implementação

4.3.1 – Conjunto de Tecnologias

As tecnologias descritas nesta secção foram selecionadas com base nos critérios e decisões arquiteturais definidos na secção 4.2.1. A seleção foi orientada por critérios de adequação ao domínio farmacêutico, qualidade das respostas, facilidade de integração, custo operacional e compatibilidade com os requisitos de rastreabilidade e implementação local exigidos pelo RGPD e pelo EU AI Act, conforme descrito na secção 2.4.3.

O **LangChain** foi escolhido como *framework* de orquestração por ser a solução mais madura e amplamente adotada para o desenvolvimento de *pipelines* RAG, com suporte nativo para as restantes componentes do conjunto e documentação extensa. A sua arquitetura modular permite substituir componentes individualmente sem reconstruir o *pipeline*, o que está alinhado com o requisito de manutenibilidade do sistema (RNF06).

O **Claude 3.5 Sonnet** da Anthropic foi selecionado como modelo generativo por apresentar, em avaliações independentes, menor taxa de alucinações e maior fidelidade ao contexto em tarefas de resposta a perguntas sobre documentos técnicos, comparativamente a modelos

alternativos. Estas características são particularmente relevantes num sistema farmacêutico de alto risco, onde respostas incorretas sobre dosagens, interações medicamentosas ou contraindicações podem ter consequências graves para o doente. Adicionalmente, o Claude foi desenvolvido com uma abordagem de Constitutional AI que o torna naturalmente mais cauteloso em domínios sensíveis, o que está alinhado com os requisitos de fiabilidade e segurança do sistema.

O modelo de *embedding* **Gemini Embedding 2** da Google foi escolhido por apresentar suporte nativo a documentos PDF e a mais de 100 línguas, incluindo português, o que o torna particularmente adequado ao corpus farmacêutico utilizado. Em comparação com o *text-embedding-3-small* da OpenAI, que foi inicialmente considerado pela sua estabilidade e integração madura com LangChain, o Gemini *Embedding 2* oferece representações semânticas de maior qualidade para texto técnico multilíngue e suporte direto ao formato dos documentos indexados. À data de implementação deste projeto, o modelo encontra-se disponível via API da Google AI, com integração suportada pelo LangChain.

O **Qdrant** foi selecionado como base de dados vetorial por suportar recuperação híbrida, combinando pesquisa semântica com pesquisa por palavra-chave, o que é um requisito do sistema para melhorar a precisão em consultas com nomes específicos de medicamentos ou princípios ativos. Adicionalmente, o Qdrant suporta filtragem por metadados, o que permite restringir a recuperação a tipos específicos de documentos (RF13), e permite disponibilização local via Docker em conformidade com os requisitos de privacidade.

O **FastAPI** foi escolhido para a exposição da API REST por ser a *framework* Python de referência para o desenvolvimento de APIs de alto desempenho, com validação automática de entradas, documentação interativa gerada automaticamente via Swagger UI e integração nativa com Python. A utilização de uma API REST permite ainda que o sistema seja futuramente integrado com outros sistemas clínicos ou farmacêuticos.

O **Docker** foi adotado para o empacotamento e disponibilização do sistema, garantindo que o ambiente de execução é reproduzível independentemente da infraestrutura subjacente, o que facilita a disponibilização local em conformidade com os requisitos de privacidade (RNF04) e simplifica a manutenção e atualização do sistema.

4.3.2 - Processamento e Indexação de Documentos

4.3.3 - Recuperação e Geração de Respostas

4.3.4 - Interface e Disponibilização

5 - Avaliação e Resultados – por fazer

5.1 - Métricas de Avaliação

5.2 - Resultados

5.3 - Discussão

6 – Conclusão - por fazer

Referências

- Borishetty, D., Banda, P., Andhi, N., Desai, A., Uppili, B. R., Reddy Bobbili, D., & Rangarajan Iyer, G. (2025). PGxRAG: A retrieval augmented generation supported pharmacogenomics assistant. *medRxiv*. <https://doi.org/10.1101/2025.09.24.25336524>
- Bossenz, J., Günzl, C., Berns, F., Weise, A., Jäger, C., Kirchhoff, J., Christoph, J., & Demus, C. (2025). Evaluation of *chunking* and *embedding* strategies for local document retrieval using an open-source LLM in a hospital. *Studies in Health Technology and Informatics*, 331, 91–100.
- Bunnell, D. J., Bondy, M. J., Fromtling, L. M., Ludeman, E., & Gourab, K. (2025). Bridging AI and healthcare: A scoping review of retrieval-augmented generation - ethics, bias, transparency, improvements, and applications. *medRxiv*. <https://doi.org/10.1101/2025.04.01.25325033>
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*. <https://arxiv.org/abs/2309.15217>
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*. <https://arxiv.org/abs/2312.10997>
- Guo, Z., Xia, L., Yu, Y., Ao, T., & Huang, C. (2024). LightRAG: Simple and fast retrieval-augmented generation. *arXiv preprint arXiv:2410.05779*. <https://arxiv.org/abs/2410.05779>
- Kim, J., Hur, M., & Min, M. (2025). From RAG to QA-RAG: Integrating generative AI for pharmaceutical regulatory compliance process. *Proceedings of the 40th ACM/SIGAPP Symposium on Applied Computing (SAC '25)*, 1293–1295. <https://doi.org/10.1145/3672608.3707749>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33. <https://arxiv.org/abs/2005.11401>
- Liu, N., Yang, R., Wong, M. Y. H., Li, H., Li, X., Zhu, W., Liao, J., Yu, K., Liew, J. C. K., Xuan, W., Chen, Y., Ke, Y., Ong, J. C. L., Teodoro, D., Hong, C., & Ting, D. S. W. (2025). Retrieval-augmented generation in medicine: A scoping review of technical implementations, clinical applications, and ethical considerations. *arXiv preprint arXiv:2511.05901*. <https://arxiv.org/abs/2511.05901>
- Liu, S., McCoy, A. B., & Wright, A. (2025). Improving large language model applications in biomedicine with retrieval-augmented generation: A systematic review, meta-analysis, and clinical development guidelines. *Journal of the American Medical Informatics Association*, 32(4), 605–615. <https://doi.org/10.1093/jamia/ocaf008>
- Page, M. J., Moher, D., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T.,

Loder, E. W., Mayo-Wilson, E., McDonald, S., ... & McKenzie, J. E. (2021). PRISMA 2020 explanation and elaboration: Updated guidance and exemplars for reporting systematic reviews. *BMJ*, 372, n160.

Peng, B., Zhu, Y., Liu, Y., Bo, X., Shi, H., Hong, C., Zhang, Y., & Tang, S. (2024). Graph retrieval-augmented generation: A survey. *ACM Transactions on Information Systems*, 44(2). <https://doi.org/10.1145/3777378>

Sarathi, P., Abdullah, S., Tuli, A., Khanna, S., Goldie, A., & Manning, C. D. (2024). RAPTOR: Recursive abstractive processing for tree-organized retrieval. *arXiv preprint arXiv:2401.18059*. <https://arxiv.org/abs/2401.18059>

Singh, A., Ehtesham, A., Kumar, S., & Khoei, T. T. (2025). Agentic retrieval-augmented generation: A survey on agentic RAG. *arXiv preprint arXiv:2501.09136*. <https://arxiv.org/abs/2501.09136>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.

Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). Benchmarking retrieval-augmented generation for medicine. *arXiv preprint arXiv:2402.13178*. <https://arxiv.org/abs/2402.13178>